PEC 1 - Análisis de datos ómicos

Nombre: Sergio Moya Millán

Fecha: 27/3/2025

Enlace a Github: https://github.com/docktoo/Moya-Millan-Sergio-PEC1.git

Índice

1. Introducción 3
2. Objetivo 3
3. Materiales y métodos. 3
   3.1. Análisis Exploratorio 4
4. Interpretación biológica 8

1. Introducción

El presente análisis se lleva a cabo utilizando un conjunto de datos ampliamente utilizado en estudios de metabolómica, conocido como el cachexia dataset. Este dataset es accesible a través de la plataforma MetaboAnalyst y ha sido utilizado en numerosos tutoriales para la enseñanza de métodos estadísticos y análisis de datos de metabolómica. El archivo de datos incluye mediciones de metabolitos en muestras de pacientes con y sin cachexia.

La cachexia es una condición médica compleja que se caracteriza por la pérdida progresiva de masa muscular y grasa corporal, generalmente asociada con enfermedades crónicas graves como el cáncer, la insuficiencia renal, y enfermedades cardíacas. Esta condición no solo afecta la calidad de vida del paciente, sino que también puede influir negativamente en la respuesta al tratamiento y en el pronóstico de la enfermedad subyacente. El análisis de metabolitos en estos pacientes ha ganado relevancia, ya que permite entender los mecanismos metabólicos involucrados en la cachexia y cómo estos podrían ser modulados para mejorar el manejo clínico de los pacientes.

2. Objetivo

El objetivo principal de este estudio es realizar un análisis comparativo entre las concentraciones de metabolitos en pacientes con cachexia y un grupo control. El análisis se realizará mediante el uso de herramientas estadísticas, como las pruebas t, para identificar metabolitos que estén significativamente asociados con la condición de cachexia. A través de este análisis, buscamos proporcionar una visión más clara de las alteraciones metabólicas presentes en los pacientes cachexicos y cómo estas pueden diferir de los individuos saludables.

3. Materiales y métodos.

3.1. Creación del objeto SummarizedExperiment

Antes de la creación del objeto se hace un análisis de los datos de metabolitos de un conjunto de pacientes, con el objetivo de explorar y procesar la información para realizar comparaciones entre grupos de pacientes que sufren pérdida muscular. En primer lugar, se cargan y organizan los datos en dos matrices: una de metadatos (que contiene la información sobre los pacientes) y otra con los valores de los metabolitos. Luego, se transponen los datos de los metabolitos para que cada columna represente un paciente y cada fila un metabolito, lo que facilita el análisis posterior.

A continuación, se crea un objeto SummarizedExperiment que incluye tanto los datos de los metabolitos como los metadatos de los pacientes, lo cual es una estructura adecuada para análisis de datos biológicos en R. Posteriormente, el script realiza un resumen de los datos, mostrando la información clave de la

estructura del objeto SummarizedExperiment (Fig. 1) y verificando la distribución de los datos, especialmente la variable MuscleLoss, que divide a los pacientes en dos grupos. Finalmente, se exploran las primeras filas de los datos de metabolitos para comprobar que los datos han sido cargados correctamente y están listos para un análisis más profundo, como pruebas estadísticas y visualizaciones.

```
class: SummarizedExperiment
dim: 63 77
metadata(0):
assays(1): counts
rownames(63): 1,6-Anhydro-beta-D-glucose 1-Methylnicotinamide ... pi-Methylhistidine tau-Methylhistidine
rowData names(0):
colnames(77): PIF_178 PIF_087 ... NETL_003_V1 NETL_003_V2
colData names(2): PatientID MuscleLoss
```

Figura 1: Resumen del objeto creado mediante el comando de R.

3.2. Análisis Exploratorio

El objetivo es generar gráficos de boxplot (Fig. 2) para visualizar la distribución de los niveles de metabolitos en función de la variable MuscleLoss, que indica la presencia o ausencia de pérdida muscular en los pacientes. En primer lugar, se define una función denominada create_plot, la cual tiene como parámetros los datos de un metabolito y su nombre. Esta función crea un gráfico de caja utilizando ggplot2, mostrando la distribución del metabolito entre las muestras con o sin pérdida muscular. El gráfico generado tiene etiquetas personalizadas para los ejes, y el título se ajusta dinámicamente al nombre del metabolito. El resto de boxplots estarán disponibles en el enlace a GitHub.

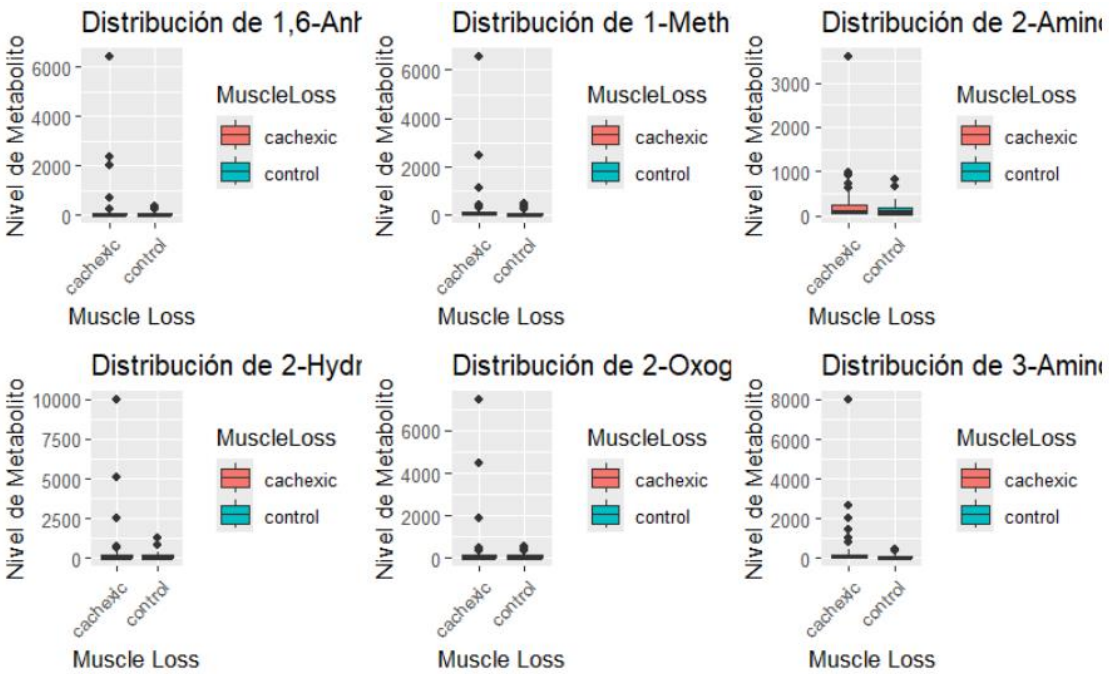

Figura 2: Distribución de los datos mediante boxplot.

A continuación, se realiza un análisis estadístico de los metabolitos en relación con la pérdida muscular (MuscleLoss) de los pacientes, utilizando

pruebas t para comparar los niveles de cada metabolito entre los dos grupos: aquellos con la enfermedad y el control. Primero, se extraen los datos de los metabolitos y los metadatos de los pacientes desde el objeto SummarizedExperiment. Estos datos se organizan en dos variables: metabolite_data que contiene la información sobre los metabolitos, y patient_info que incluye información sobre los pacientes.

A continuación, se definen los dos grupos para la variable MuscleLoss utilizando la función unique() para obtener los grupos de pacientes con y sin enfermedad. El script luego realiza un ciclo for que recorre cada metabolito y lleva a cabo una prueba t de Student para comparar los valores de ese metabolito entre los dos grupos. Los resultados de la prueba t, como la estadística t y el p-valor, se almacenan en un dataframe llamado t_test_results.

Una vez obtenidos los resultados de las pruebas t, el script filtra aquellos metabolitos cuyo p-valor es inferior a 0.05, considerando que tienen una diferencia estadísticamente significativa entre los dos grupos. Estos metabolitos se almacenan en el dataframe significant_metabolites (Fig. 3).

Metabolite	t_statistic	p_value
Valine	4.641910	1.574212e-05
N,N-Dimethylglycine	4.551818	2.114015e-05
Leucine	4.528109	2.662822e-05
Quinolinate	4.471899	2.708732e-05
Dimethylamine	4.323232	5.348990e-05

Figura 3: Los cinco metabolitos más significativos.

Por último, se generan gráficos de caja para los metabolitos que muestran diferencias significativas entre los grupos de pérdida muscular. Para cada metabolito significativo, se crea un gráfico que muestra la distribución del metabolito entre los grupos de pacientes con y sin pérdida muscular. Estos gráficos permiten visualizar de forma clara las diferencias en los niveles de los metabolitos entre los dos grupos y proporcionan una herramienta visual para interpretar los resultados estadísticos obtenidos previamente. La figura 4 muestra el metabolito más significativo de toda la lista, el resto se encuentra en el repositorio de Github.

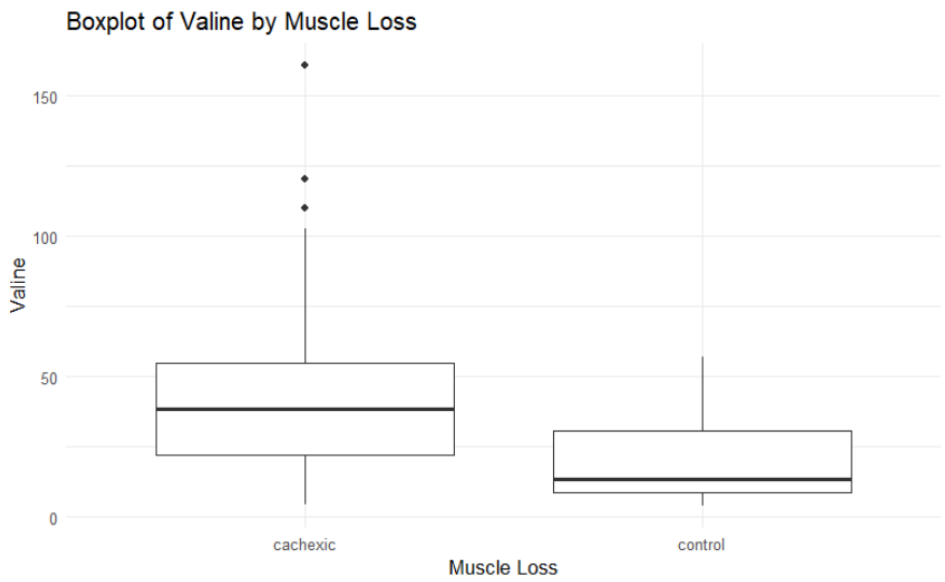

Figura 4: Representación gráfica mediante Boxplot del metabolito más significativo.

3.3. Análisis de correlaciones

Después, se ha calculado una matriz de correlación entre los metabolitos, lo que permite identificar las relaciones entre las distintas variables de metabolitos en el conjunto de datos. Para ello, se transponen los datos de metabolitos y se calcula la correlación utilizando la función cor(), que da como resultado una matriz que muestra qué tan fuertemente se correlacionan los metabolitos entre sí. Posteriormente, esta matriz de correlación se visualiza mediante un heatmap (Fig. 5), donde las relaciones de correlación se representan en una escala de colores, lo que facilita la interpretación visual. En este mapa de calor, el color rojo indica una alta correlación positiva, el azul una alta correlación negativa y el blanco representa una correlación cercana a cero.

Los resultados que nos muestran las correlaciones altas entre metabolitos en este análisis pueden sugerir patrones biológicos e interacciones metabólicas clave en la fisiología de los pacientes con caquexia. Las tres correlaciones mas altas són Valina y Leucina (correlación de 0,88), Serina y Glutamina (correlación de 0,87), y Citrato y cis-Aconitato (correlación de 0,86).

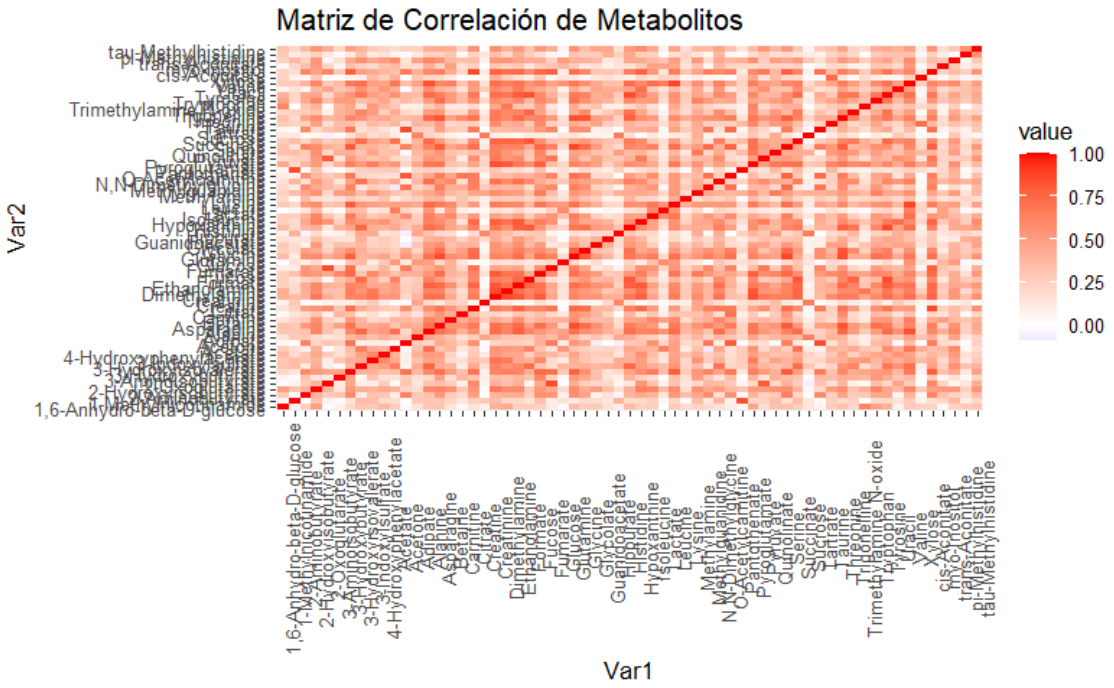

Figura 5: Mapa de calor de las correlaciones de metabolitos.

3.4. Análisis de componentes principales

A continuación, se ha realizado un Análisis de Componentes Principales (PCA) para reducir la dimensionalidad de los datos y facilitar la visualización de la variabilidad entre los grupos de pacientes (cachexia y control). El PCA busca identificar las direcciones principales en las que varían los datos y proyectarlos sobre un espacio de menor dimensión, manteniendo la mayor cantidad de variabilidad posible. Para seleccionar los componentes principales, se selecciona cuyos eigenvalues sean mayor que 1, en nuestro caso nos quedamos con 12 componentes (Fig. 6).

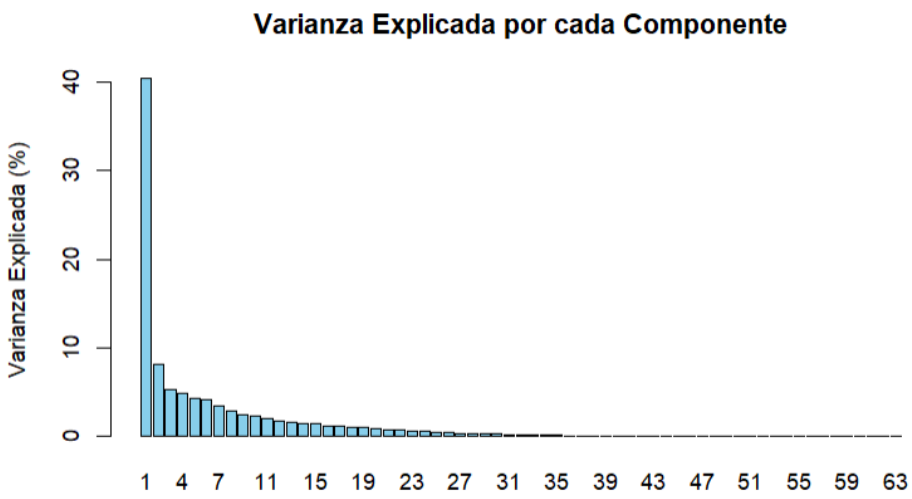

Figura 6: Grafico de la varianza explicada

En este caso, se han utilizado las dos primeras componentes principales (PC1 y PC2) para representar visualmente la separación entre los pacientes de los dos grupos (Fig. 7). El gráfico resultante permite observar si existe una distinción clara entre los pacientes de cachexia y control, utilizando diferentes colores para los grupos. Este análisis es útil para identificar patrones generales en los datos, como la posible separación entre grupos en función de los metabolitos medidos.

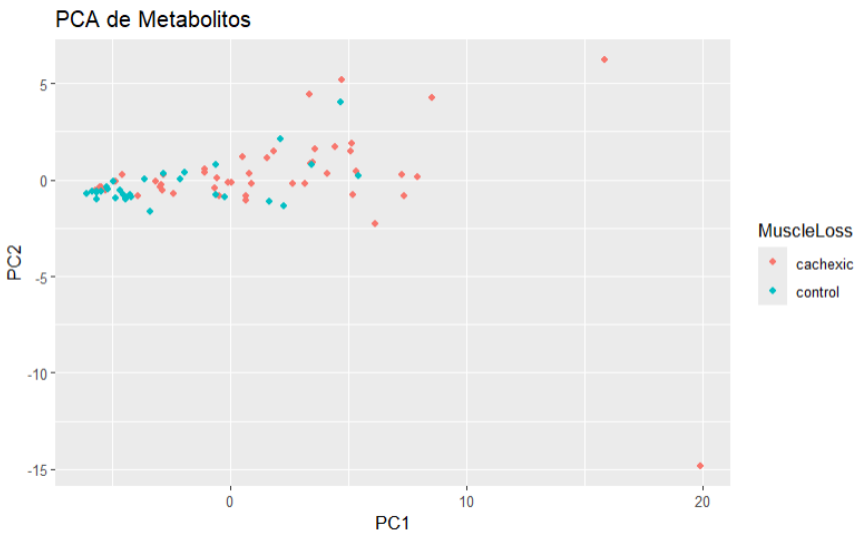

Figura 7: Grafico de ACP de la componente 1 y 2

4. Interpretación biológica

Los metabolitos con correlaciones altas (como la valina, leucina, glutamina, entre otros) y los resultados estadísticos (como los valores de p bajos y las estadísticas t significativas) indican que estos metabolitos podrían tener un rol crucial en el metabolismo muscular y energético de los pacientes con caquexia. La valina y leucina, en particular, están directamente relacionadas con la síntesis de proteínas musculares, mientras que otros metabolitos como dimetilamina y pirroglutamato están involucrados en el metabolismo de aminoácidos y energía celular.

La alteración en las concentraciones de estos metabolitos podría reflejar un desequilibrio en las rutas metabólicas clave que son esenciales para el mantenimiento de la masa muscular y la función energética, dos factores que se ven gravemente afectados en la caquexia. Estos metabolitos, por lo tanto, no solo proporcionan información sobre los procesos metabólicos subyacentes en la enfermedad, sino que también podrían servir como biomarcadores para el diagnóstico temprano o la evaluación de la progresión de la caquexia.

Por otra parte, el análisis de componentes principales no se identifica patrones o grupos en los datos. Si que se observa valores muy distantes o outliers que podría ser pacientes que han generado una respuesta metabólica distinta o un error en los datos.

En resumen, la combinación de correlaciones metabólicas, valores de p significativos y estadísticas t altas subraya la importancia de estos metabolitos en el metabolismo energético y proteico en caquexia, sugiriendo posibles puntos de intervención terapéutica.